

Introduction - biais et équité algorithmique

François HU

consultant R&D, responsable du pôle Intelligence Artificielle



Une attention grandissante sur l'équité dans différents secteurs

Des déficiences qui matérialisent déjà un risque de réputation sur quelques cas concrets couvrant la chaîne de valeur

Scoring

Dans un article publié dans Science en 2019 (1), et rendu public par Microsoft (2), il a été démontré qu'un **algorithme commercial de prédiction du score de santé** utilisé à l'hôpital était biaisé au regard de l'ethnicité : « **à un score de risque donné, les patients noirs sont considérablement plus malades que les patients blancs** ». L'article met l'accent sur les conséquences de ce biais, affirmant que « *remédier à cette disparité ferait passer le pourcentage de patients noirs recevant une aide supplémentaire de 17,7 % à 46,5 %* »

Fraude

En France, une enquête récente (4) a ciblé les Caisses d'Allocations Familiales. Elles utilisent un algorithme interne qui attribue des scores de risque de fraude pour répartir les efforts de ses ~700 contrôleurs entre les ~14 millions de ménages bénéficiaires. Selon l'étude, **les scores dépendent fortement d'attributs protégés, notamment le handicap et la situation familiale**, et le système n'a pas été testé récemment pour détecter les biais de discrimination.

Indemnisation 1

En 2022, une étude (4) a évalué la **discrimination raciale** liée à la résolution des sinistres dans le cadre de l'assurance contre les tremblements de terre. L'étude a montré que les demandes d'indemnisation émanant de régions où la **population noire est plus nombreuse avaient moins de chances d'aboutir à un paiement**, et qu'en cas de paiement, celui-ci était plus faible dans ces régions.

Indemnisation 2

Une étude (5) à la base du procès en cours concernant l'assureur State Farm aux Etats-Unis a montré que les populations noire et blanche parmi un panel d'assurés présentaient des **disparités de traitement en termes de délai, de volume de documents supplémentaires demandés et d'interactions nécessaires** auprès de représentants de State Farm avant de procéder à l'indemnisation. Le cadre du procès intègre également **l'analyse des règles automatiques produites par un logiciel tiers**, notamment basées sur des données caractérisant le lieu de vie.

(1) Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366(6464), 447-453.

(2) <https://www.microsoft.com/en-us/research/video/dissecting-racial-bias-in-an-algorithm-that-guides-health-decisions-for-millions/>

(3) https://www.lemonde.fr/les-decodeurs/article/2023/12/06/algorithme-des-caf-le-departement-de-seine-saint-denis-saisit-la-defenseure-des-droits_6204180_4355770.html

(4) Lin, X., Browne, M. J., and Hofmann, A. (2022). Race discrimination in the adjudication of claims: Evidence from earthquake insurance. Journal of Risk and Insurance.

(5) <https://www.insurancejournal.com/news/national/2022/12/16/699788.html>



Équité algorithmique

► Introduction

Introduction sur l'équité algorithmique

Notion de discrimination, dimensions de l'équité, et processus de modélisation

Discrimination

La discrimination fait référence à des distinctions injustifiées entre des individus sur la base de leur appartenance à un certain groupe.

Au-delà des variables dont l'utilisation est proscrite par la réglementation selon les cas (origine, genre, situation de handicap...), la notion de **variable sensible** peut être étendue à **l'ensemble des variables** sur lesquelles opérer une distinction n'est pas justifié ou souhaité

Dimensions de l'équité


Groupe : La population du groupe privilégié est-elle traitée de la même manière que la population non privilégiée ?

Individu : La prédiction serait-elle la même pour un individu donné s'il avait appartenu au groupe privilégié ?

Discrimination dans le processus de modélisation

Dans la mesure où les attributs sensibles ont un impact sur les variables individuelles (**A**) et peuvent être utilisés directement dans le processus de modélisation (**B**), les biais peuvent déjà être identifiés dans les **données d'entrée**.

En outre, dans le cadre du processus de modélisation, la prédiction exploite toutes les variables disponibles pour maximiser la segmentation et la performance prédictive. De ce fait, le modèle peut potentiellement déformer, augmenter et même créer des biais dans les **résultats prédits** (**C**).



Identification des métriques d'équité

Deux métriques fondamentales pour mesurer et assurer l'équité de groupe

Parité Démographique (ou indépendance)

Lorsque les scores / prédictions sont similaires si l'on compare les deux populations. Cette métrique est adaptée dans le cas où **le risque est relativement indépendant de la variable sensible, ou lorsque les observations sont biaisées pour la population minoritaire.**

Exemple : dans le cas d'un algorithme de scoring de fraude, le score moyen sur la population de femmes est de 2%, ce qui est aussi le cas au sein de la population homme. L'algorithme est dit **'équitable pour le genre au sens de la parité démographique'**

$$\mathbb{P}(\hat{Y} = 1 | S = \text{homme}) = \mathbb{P}(\hat{Y} = 1 | S = \text{femme})$$

Point d'attention : cette métrique ne tient pas compte de la réalité du risque observé dans les différents groupes, et n'est donc pas adaptée si des facteurs de risque sont dépendants de la variable sensible

Egalité des chances (ou séparation)

Lorsque la performance du modèle est similaire si l'on compare les deux populations. Cette métrique est adaptée dans le cas où **le risque est lié à la variable sensible, et lorsque les observations ne sont pas biaisées pour la population minoritaire.**

Exemple : dans le cas d'un modèle estimant la probabilité d'obtenir un sinistre grave en assurance auto, le taux de vrais positifs pour la population de femmes est de 97%, ce qui est aussi le cas au sein de la population homme. L'algorithme est dit **'équitable pour le genre au sens de l'égalité des opportunités'**.

$$\mathbb{P}(\hat{Y} = 1 | Y = 1, S = \text{homme}) = \mathbb{P}(\hat{Y} = 1 | Y = 1, S = \text{femme})$$

L'algorithme est dit **'équitable au sens de l'égalité des chances'** si les taux de faux positifs sont également égaux.

Point d'attention : cette métrique ne tenant pas compte du score / prédiction au global dans chacun des groupes, elle n'est donc pas adaptée si les données souffrent de biais de représentation.

Les métriques de parité démographique et d'égalité des chances ne sont pas compatibles entre elles

Autres métriques d'équité

Point de vue du **décideur**

Conditionnement **selon le résultat** :

Exemple : en matière de prêts bancaires, ceux qui feront défaut devraient avoir la même probabilité de rejet, quelle que soit par exemple leur couleur de peau.

Conditionnement **selon le décideur** :

Exemple : les personnes ayant subi la même décision auraient eu des résultats similaires, indépendamment du groupe.

independence, $\hat{Y} \perp\!\!\!\perp S$,

statistical parity

$$\mathbb{P}[\hat{Y} = 1 | S = s] = \text{cst}, \forall s$$

conditional statistical parity

$$\mathbb{P}[\hat{Y} = 1 | S = s, X = x] = \text{cst}_x, \forall s, x$$

separation, $\hat{Y} \perp\!\!\!\perp S | Y$,

equalized odds

$$\mathbb{P}[\hat{Y} = 1 | S = s, Y = y] = \text{cst}_y, \forall s, y$$

equalized opportunity

$$\mathbb{P}[\hat{Y} = 1 | S = s, Y = 1] = \text{cst}, \forall s$$

predictive equality

$$\mathbb{P}[\hat{Y} = 1 | S = s, Y = 0] = \text{cst}, \forall s$$

balance

$$\mathbb{E}[M | S = s, Y = 1] = \text{cst}_y, \forall s, y$$

sufficiency, $Y \perp\!\!\!\perp S | \hat{Y}$,

disparate mistreatment

$$\mathbb{P}[Y = y | S = s, \hat{Y} = y] = \text{cst}_y, \forall s, y$$

predictive parity

$$\mathbb{P}[Y = 1 | S = s, \hat{Y} = 1] = \text{cst}, \forall s$$

calibration

$$\mathbb{P}[Y = 1 | M = m, S = s] = \psi(m), \forall m, s$$

well-calibration

$$\mathbb{P}[Y = 1 | M = m, S = s] = m, \forall m, s$$



Pour plus d'informations, cf. Arthur Charpentier « *Insurance, Biases, Discrimination and Fairness in Insurance* »

Illustrations avec la matrice de confusion

Considérer le résultat vs considérer la décision

Décision

Résultat

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \hat{Y})$	$\mathbb{P}(Y = 1 \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 Y)$	$\mathbb{P}(\hat{Y} = 0 Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 Y)$	$\mathbb{P}(\hat{Y} = 1 Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 Y = 1)$ TVP		



Groupe S = -1
(exemple homme)

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \hat{Y})$	$\mathbb{P}(Y = 1 \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 Y)$	$\mathbb{P}(\hat{Y} = 0 Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 Y)$	$\mathbb{P}(\hat{Y} = 1 Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 Y = 1)$ TVP		

Groupe S = +1
(exemple femme)



Illustrations avec la matrice de confusion

L'objectif est d'obtenir **les mêmes blocs** pour chaque valeur de l'attribut sensible

Les blocs à gauche et à droite doivent être **égaux pour être équitables** selon la notion de

Indépendance : $\hat{Y} \perp S$

Décision

Résultat

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \hat{Y})$	$\mathbb{P}(Y = 1 \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 Y)$	$\mathbb{P}(\hat{Y} = 0 Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 Y)$	$\mathbb{P}(\hat{Y} = 1 Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 Y = 1)$ TVP		



Groupe $S = -1$
(exemple homme)

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \hat{Y})$	$\mathbb{P}(Y = 1 \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 Y)$	$\mathbb{P}(\hat{Y} = 0 Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 Y)$	$\mathbb{P}(\hat{Y} = 1 Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 Y = 1)$ TVP		

Groupe $S = +1$
(exemple femme)



Illustrations avec la matrice de confusion

L'objectif est d'obtenir **les mêmes blocs** pour chaque valeur de l'attribut sensible

Les blocs à gauche et à droite doivent être **égaux pour être équitables** selon la notion de

Séparation : $(\hat{Y} \perp S) \mid Y$

Décision

Résultat

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \mid \hat{Y})$	$\mathbb{P}(Y = 1 \mid \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \mid \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \mid \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 \mid Y)$	$\mathbb{P}(\hat{Y} = 0 \mid Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 \mid Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 \mid Y)$	$\mathbb{P}(\hat{Y} = 1 \mid Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 \mid Y = 1)$ TVP		



Groupe $S = -1$
(exemple homme)

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \mid \hat{Y})$	$\mathbb{P}(Y = 1 \mid \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \mid \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \mid \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 \mid Y)$	$\mathbb{P}(\hat{Y} = 0 \mid Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 \mid Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 \mid Y)$	$\mathbb{P}(\hat{Y} = 1 \mid Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 \mid Y = 1)$ TVP		

Groupe $S = +1$
(exemple femme)



Illustrations avec la matrice de confusion

L'objectif est d'obtenir **les mêmes blocs** pour chaque valeur de l'attribut sensible

Les blocs à gauche et à droite doivent être **égaux pour être équitables** selon la notion de

Suffisance : $(Y \perp S) \mid \hat{Y}$

Décision

Résultat

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \mid \hat{Y})$	$\mathbb{P}(Y = 1 \mid \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \mid \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \mid \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 \mid Y)$	$\mathbb{P}(\hat{Y} = 0 \mid Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 \mid Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 \mid Y)$	$\mathbb{P}(\hat{Y} = 1 \mid Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 \mid Y = 1)$ TVP		



Groupe $S = -1$
(exemple homme)

	Y = 0	Y = 1	$\mathbb{P}(Y = 0 \mid \hat{Y})$	$\mathbb{P}(Y = 1 \mid \hat{Y})$
$\mathbb{P}(\hat{Y} = 0)$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \mid \hat{Y} = 0)$ Taux fausses omissions
$\mathbb{P}(\hat{Y} = 1)$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \mid \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \mid \hat{Y} = 1)$ Taux vrais découvertes
$\mathbb{P}(\hat{Y} = 0 \mid Y)$	$\mathbb{P}(\hat{Y} = 0 \mid Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 \mid Y = 1)$ TFN		
$\mathbb{P}(\hat{Y} = 1 \mid Y)$	$\mathbb{P}(\hat{Y} = 1 \mid Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 \mid Y = 1)$ TVP		

Groupe $S = +1$
(exemple femme)



Diagnostic des biais

- ▶ Evaluer l'équité algorithmique

Evaluation empirique des scores (1/2)

L'objectif est d'obtenir **les mêmes blocs** pour chaque valeur de l'attribut sensible

Analyser les prédictions

Indépendance : $\hat{Y} \perp S$

		Résultat			
		Y = 0	Y = 1	$\mathbb{P}(Y = 0 \hat{Y})$	$\mathbb{P}(Y = 1 \hat{Y})$
Décision	$\hat{Y} = 0$	Vrai Négatif (VN)	Faux Négatif (FN)	$\mathbb{P}(Y = 0 \hat{Y} = 0)$ Taux vrais omissions	$\mathbb{P}(Y = 1 \hat{Y} = 0)$ Taux fausses omissions
	$\hat{Y} = 1$	Faux Positif (FP)	Vrai Positif (VP)	$\mathbb{P}(Y = 0 \hat{Y} = 1)$ Taux fausses découvertes	$\mathbb{P}(Y = 1 \hat{Y} = 1)$ Taux vrais découvertes
		$\mathbb{P}(\hat{Y} = 0 Y)$	$\mathbb{P}(\hat{Y} = 0 Y = 0)$ TVN	$\mathbb{P}(\hat{Y} = 0 Y = 1)$ TFN	
		$\mathbb{P}(\hat{Y} = 1 Y)$	$\mathbb{P}(\hat{Y} = 1 Y = 0)$ TFP	$\mathbb{P}(\hat{Y} = 1 Y = 1)$ TVP	

Suffisance : $(Y \perp S) | \hat{Y}$

Séparation : $(\hat{Y} \perp S) | Y$

Groupe $S = -1$
(exemple homme)



Groupe $S = +1$
(exemple femme)




Evaluation empirique des scores (2/2)

Notion de **calibration**

Analyser les scores

Comme expliqué dans Van Calster et al. (2019), "parmi les patients ayant un risque estimé de 20 %, nous nous attendons à ce que 20 sur 100 aient ou développent l'événement."

- Si 40 sur 100 de ce groupe sont trouvés atteints de la maladie, le risque est **sous-estimé**.
- Si nous observons que dans ce groupe, 10 sur 100 ont la maladie, le risque est **sur-estimé**.



Evaluation empirique des scores (2/2)


Notion de **calibration** par groupe

Analyser les scores


Cette fois-ci, on considère un modèle m estimant la **probabilité de développer une maladie** pour différents individus. On souhaite que ce modèle respecte le critère *multicalibration*, c.a.d. :

$$\forall p \in [0, 1], \mathbb{P}(Y = 1 | m(X, S) = p, S = -1) = \mathbb{P}(Y = 1 | m(X, S) = p, S = 1) = p.$$

Modèle m initial



Modèle m respectant la *multicalibration*



Remédiation des biais

Etudes de cas en assurance


Scores de mortalité

Équité Ethnique dans les Prédictions de Mortalité (GOSSIS)

Nous évaluons l'équité en termes d'ethnicité pour la **classification de la mortalité sur le jeu de données GOSSIS**, qui comprend plus de 130 000 visites en soins intensifs sur une année dans des hôpitaux de divers pays.

Nous appliquons une méthode basée sur les **multiplicateurs de Lagrange** pour générer des prédictions équitables, que nous comparons aux prédictions initiales du modèle Apache IV, fondé sur le score APACHE III et d'autres variables, y compris le diagnostic.

Model output distribution



Rappel 1 – Performance prédictive et le seuil de décision

Evaluation empirique des scores

Matrice de confusion et AUC : la notion de seuil de décision

<i>Occurrence sinistre</i>	<i>Score</i>	<i>Prédiction (seuil 0.5)</i>
0	0.4	0
1	0.7	1
1	0.35	0
0	0.52	1
1	0.68	1
0	0.2	0
0	0.1	0
0	0.6	1
1	0.7	1
0	0.55	1

Exemple illustratif

► Approche 1 : Matrice de confusion

Mesure la performance des modèles de classification à 2 classes ou plus.
Dans le cas binaire, la matrice de confusion est un tableau à 4 valeurs représentant différentes combinaisons de valeurs réelles et valeurs prédites

		Réalité	
		Négative : 0	Positive : 1
Prédiction	Négative : 0	Vrai Négatif	Faux Négatif
	Positive : 1	Faux Positif	Vrai Positif



Performance

Equité

Evaluation empirique des scores

Matrice de confusion et AUC : la notion de seuil de décision

Occurrence sinistre	Score	Prédiction (seuil 0.5)
0	0.4	0
1	0.7	1
1	0.35	0
0	0.52	1
1	0.68	1
0	0.2	0
0	0.1	0
0	0.6	1
1	0.7	1
0	0.55	1

Accuracy : 0.6

(TFP, TVP) (0.25, 0.5)

Exemple illustratif

► Approche 1 : Matrice de confusion

Mesure la performance des modèles de classification à 2 classes ou plus.
Dans le cas binaire, la matrice de confusion est un tableau à 4 valeurs représentant différentes combinaisons de valeurs réelles et valeurs prédites

		Réalité	
		Négative : 0	Positive : 1
Prédiction	Négative : 0	3	1
	Positive : 1	3	3

→ **Précision** : $\frac{3}{6} = 0.5$

Taux de Vrais Négatifs (spécificité) : $\frac{3}{6} = 0.5$ Taux de Vrais Positifs (sensibilité ou rappel) : $\frac{3}{4} = 0.75$



Performance

Equité

Evaluation empirique des scores

Matrice de confusion et AUC : la notion de seuil de décision

Occurrence sinistre	Score	Prédiction (seuil 0.5)	Prédiction (seuil 1)
0	0.4	0	0
1	0.7	1	0
1	0.35	0	0
0	0.52	1	0
1	0.68	1	0
0	0.2	0	0
0	0.1	0	0
0	0.6	1	0
1	0.7	1	0
0	0.55	1	0

Accuracy : 0.6 **Accuracy** : 0.6
(TFP, TVP) (0.25, 0.5) (0, 0)

Exemple illustratif

► Approche 1 : Matrice de confusion

Mesure la performance des modèles de classification à 2 classes ou plus.
Dans le cas binaire, la matrice de confusion est un tableau à 4 valeurs représentant différentes combinaisons de valeurs réelles et valeurs prédites

		Réalité	
		Négative : 0	Positive : 1
Prédiction	Négative : 0	6	4
	Positive : 1	0	0

→ **Précision** : NaN

Taux de Vrais Négatifs (spécificité) : $\frac{6}{6+0} = 1$ Taux de Vrais Positifs (sensibilité ou rappel) : $\frac{0}{0+4} = 0$



Performance

Equité

Evaluation empirique des scores

Matrice de confusion et AUC : la notion de seuil de décision

Occurrence sinistre	Score	Prédiction (seuil 0.5)	Prédiction (seuil 1)	Prédiction (seuil 0.65)
0	0.4	0	0	0
1	0.7	1	0	1
1	0.35	0	0	0
0	0.52	1	0	0
1	0.68	1	0	1
0	0.2	0	0	0
0	0.1	0	0	0
0	0.6	1	0	0
1	0.7	1	0	1
0	0.55	1	0	0

Accuracy : 0.6 (TFP, TVP) Accuracy : 0.6 (0, 0) Accuracy : 0.9 (0, 0.75)

Exemple illustratif

Approche 1 : Matrice de confusion

Mesure la performance des modèles de classification à 2 classes ou plus. Dans le cas binaire, la matrice de confusion est un tableau à 4 valeurs représentant différentes combinaisons de valeurs réelles et valeurs prédites

		Réalité	
		Négative : 0	Positive : 1
Prédiction	Négative : 0	6	1
	Positive : 1	0	3

→ Précision : 1

Taux de Vrais Négatifs (spécificité) : $\frac{6}{6+0} = 1$ Taux de Vrais Positifs (sensibilité ou rappel) : $\frac{3}{3+1} = 0.75$

Indice de Youden pour choisir le meilleur seuil de décision

TFP (1 - spécificité) À minimiser !

TVP (sensibilité ou rappel) À maximiser !

Indice de Youden = max | TVP – TFP |

Evaluation empirique des scores

Matrice de confusion et AUC : la notion de seuil de décision

Exemple illustratif

Occurrence sinistre	Score	Prédiction (seuil 0.5)	Prédiction (seuil 1)	Prédiction (seuil 0.65)
0	0.4	0	0	0
1	0.7	1	0	1
1	0.35	0	0	0
0	0.52	1	0	0
1	0.68	1	0	1
0	0.2	0	0	0
0	0.1	0	0	0
0	0.6	1	0	0
1	0.7	1	0	1
0	0.55	1	0	0


Accuracy : 0.6 (TFP, TVP) **Accuracy** : 0.6 (0, 0) **Accuracy** : 0.9 (0, 0.75)

Approche 1 : Matrice de confusion

Mesure la performance des modèles de classification à 2 classes ou plus. Dans le cas binaire, la matrice de confusion est un tableau à 4 valeurs représentant différentes combinaisons de valeurs réelles et valeurs prédites

Approche 2 : AUC-ROC

L'**AUC-ROC** (Area Under the Curve - Receiver Operating Characteristic) ou **AUC** évalue la capacité d'un modèle à distinguer entre les classes en traçant le TVP contre le TFP pour différents seuils de décision. L'AUC (aire sous la courbe) varie entre 0,5 (modèle aléatoire) et 1 (modèle parfait)



Indice de GINI = 2 x AUC - 1

Des mesures « **agnostiques** » aux modèles (s'appliquent à toutes techniques : GLM, arbres de décision, ...)

Rappel 2 - Interprétation des coefficients / paramètres dans un GLM

Données types

Cas assurance auto

Coût sinistre	Occurrence sinistre	Variables quantitatives		Qualitative ordinaire	Qualitative non-ordinaire
		Age	Ancienneté	Catégorie / Classe	Garage
0	0	41	0	M2	Privé
122.3	1	20	8	M1	Privé
977.8	1	21	7	M1	Non
0	0	45	5	M1	Partagé
311.1	1	29	2	M3	Non



Tâche de régression avec une
variable cible continue

Exemple illustratif

- Sans retraitement, plusieurs difficultés
- **Variables qualitatives** : Avant l'optimisation des paramètres, il est nécessaire de les transformer en variables numériques / quantitatives.
 - **Mise en échelle des variables** : Les GLM sont sensibles à l'échelle des variables. Si les variables explicatives sont sur des échelles très différentes, cela peut rendre **difficile l'interprétation des coefficients** et leur correcte estimation.

Pour des variables quantitatives (1/3)

Cas assurance auto

		Variables quantitatives		Qualitative ordinaire	Qualitative non-ordinaire
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage
0	0	41	0	M2	Privé
122.3	1	20	8	M1	Privé
977.8	1	21	7	M1	Non
0	0	45	5	M1	Partagé
311.1	1	29	2	M3	Non

La « **standardisation** » ou la « **normalisation** » sont utiles quand on veut comparer les coefficients de variables avec des unités différentes ou même unité mais une variabilité différente

Exemple illustratif

► Variables quantitatives :

Augmenter la variable numérique d'une unité change le résultat estimé du modèle de son coefficient.

Exemple : Si le coefficient de « Âge » est de -2, cela signifie que pour chaque année supplémentaire, le coût moyen des sinistres diminue de 2 unités, toutes les autres variables étant égales par ailleurs.

Pour des variables quantitatives (3/3)

Cas assurance auto

		Variables quantitatives		Qualitative ordinaire	Qualitative non-ordinaire
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage
0	0	0.84	0	M2	Privé
122.3	1	0	1	M1	Privé
977.8	1	0.04	0.875	M1	Non
0	0	1	0.625	M1	Partagé
311.1	1	0.36	0.25	M3	Non

La « **standardisation** » ou la « **normalisation** » sont utiles quand on veut comparer les coefficients de variables avec des unités différentes ou même unité mais une variabilité différente

Exemple illustratif

Standardisation :
la variable explicative est centrée autour de 0 d'écart-type 1

$$X_{stand} = \frac{X - E[X]}{\sigma(X)}$$

Normalisation :
la variable explicative a pour valeur entre deux valeurs (généralement entre 0 et 1) :

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Pour une variable qualitative ordinaire (1/3)

Cas assurance auto

Exemple illustratif

		Variables quantitatives		Qualitative ordinaire	Qualitative non-ordinaire
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage
0	0	0.84	0	M2	Privé
122.3	1	0	1	M1	Privé
977.8	1	0.04	0.875	M1	Non
0	0	1	0.625	M1	Partagé
311.1	1	0.36	0.25	M3	Non

Variables qualitatives :

Après le *label encoding*, l'interprétation des coefficients est similaire à celle des variables quantitatives.

Exemple : Si le coefficient de « Classe » est 5, cela signifie que les véhicules avec une classe M2 ont un coût de sinistre moyen de 5 unités plus élevé que celles avec une classe M1, toutes les autres variables étant égales par ailleurs.

Label encoding : Si l'ordre entre les catégories d'une variable est pertinent, il est naturel de transformer les variables ordinales en valeurs numériques correspondantes (par exemple, M3 en 3, M2 en 2, etc.)

Pour une variable qualitative ordinaire (3/3)

Cas assurance auto

Exemple illustratif

Variables quantitatives		Qualitative ordinaire		Qualitative non-ordinaire	
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage
0	0	0.84	0	0.666	Privé
122.3	1	0	1	0.333	Privé
977.8	1	0.04	0.875	0.333	Non
0	0	1	0.625	0.333	Partagé
311.1	1	0.36	0.25	1	Non

► **Variables qualitatives :**
Après le *label encoding*, l'interprétation des coefficients est similaire à celle des variables quantitatives.

Exemple : Si le coefficient de « Classe » est 5, cela signifie que les véhicules avec une classe M2 ont un coût de sinistre moyen de 5 unités plus élevé que celles avec une classe M1, toutes les autres variables étant égales par ailleurs.

Label encoding : Si l'ordre entre les catégories d'une variable est pertinent, il est naturel de transformer les variables ordinales en valeurs numériques correspondantes (par exemple, M3 en 3, M2 en 2, etc.)

Pour une variable qualitative non-ordinale (1/3)

Cas assurance auto

Exemple illustratif

		Variables quantitatives		Qualitative ordinale	Qualitative non-ordinale
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage
0	0	0.84	0	0.666	Privé
122.3	1	0	1	0.333	Privé
977.8	1	0.04	0.875	0.333	Non
0	0	1	0.625	0.333	Partagé
311.1	1	0.36	0.25	1	Non

► **Variables qualitatives non ordinales :**
Le *one-hot encoding* est essentiel pour préparer les variables catégorielles avant de les inclure dans un modèle GLM. Il permet **d'éviter les ordres implicites indésirables** et de gérer la colinéarité, tout **en facilitant l'interprétation** des résultats du modèle.



One-hot encoding : Nécessité de transformer cette variable multi-catégorielle (non ordinale) en plusieurs variables binaires (une par catégorie), indiquant l'absence ou la présence de chaque catégorie pour l'observation.

Pour une variable qualitative non-ordinale (2/3)

Exemple illustratif

Cas assurance auto

		Variables quantitatives		Qualitative ordinale	Qualitative non-ordinale		
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage Non	Garage Partagé	Garage Privé
0	0	0.84	0	0.666	0	0	1
122.3	1	0	1	0.333	0	0	1
977.8	1	0.04	0.875	0.333	1	0	0
0	0	1	0.625	0.333	0	1	0
311.1	1	0.36	0.25	1	1	0	0



One-hot encoding : Nécessité de transformer cette variable multi-catégorielle (non ordinale) en plusieurs variables binaires (une par catégorie), indiquant l'absence ou la présence de chaque catégorie pour l'observation.

Pour une variable qualitative non-ordinale (3/3)

Cas assurance auto

Exemple illustratif

		Variables quantitatives		Qualitative ordinaire	Qualitative non-ordinale		
Coût sinistre	Occurrence sinistre	Age	Ancienneté	Catégorie / Classe	Garage Non	Garage Partagé	Garage Privé
0	0	0.84	0	0.666	0	0	1
122.3	1	0	1	0.333	0	0	1
977.8	1	0.04	0.875	0.333	1	0	0
0	0	1	0.625	0.333	0	1	0
311.1	1	0.36	0.25	1	1	0	0

Optionnel : Pour une variable comportant K catégories, il est possible de **supprimer l'une des variables binaires**, car les K-1 autres variables suffisent à représenter entièrement l'information contenue dans la variable d'origine.

Nous avons fait le choix de garder les K variables.




One-hot encoding : Nécessité de transformer cette variable multi-catégorielle (non ordinale) en plusieurs variables binaires (une par catégorie), indiquant l'absence ou la présence de chaque catégorie pour l'observation.

Importance des variables explicatives (1/2)

Des approches « simples » basées sur les coefficients

Exemple illustratif




► Approche 1 : **magnitude des coefficients**

Les coefficients estimés mesurent l'effet d'une **variation unitaire d'une variable explicative sur la variable cible**, en maintenant constantes les autres variables. Dans certains cas, les coefficients peuvent être utilisés pour évaluer l'importance relative des variables. **Plus un coefficient est grand (en valeur absolue)**, plus l'impact de la variable correspondante est important.

Importance des variables explicatives (2/2)

Des approches « simples » basées sur les coefficients

Exemple illustratif



Approche 1 : **magnitude des coefficients**

Les coefficients estimés mesurent l'effet d'une **variation unitaire d'une variable explicative sur la variable cible**, en maintenant constantes les autres variables. Dans certains cas, les coefficients peuvent être utilisés pour évaluer l'importance relative des variables. **Plus un coefficient est grand (en valeur absolue)**, plus l'impact de la variable correspondante est important.

► Approche 2 : **signification statistique (p-valeur)**

Une autre manière d'évaluer l'importance d'une variable est de tester si son coefficient est statistiquement différent de zéro. Si la **p-valeur** associée au coefficient est inférieure à un seuil conventionnel (**souvent 0.05**), la variable est considérée comme ayant un effet significatif sur la variable cible.